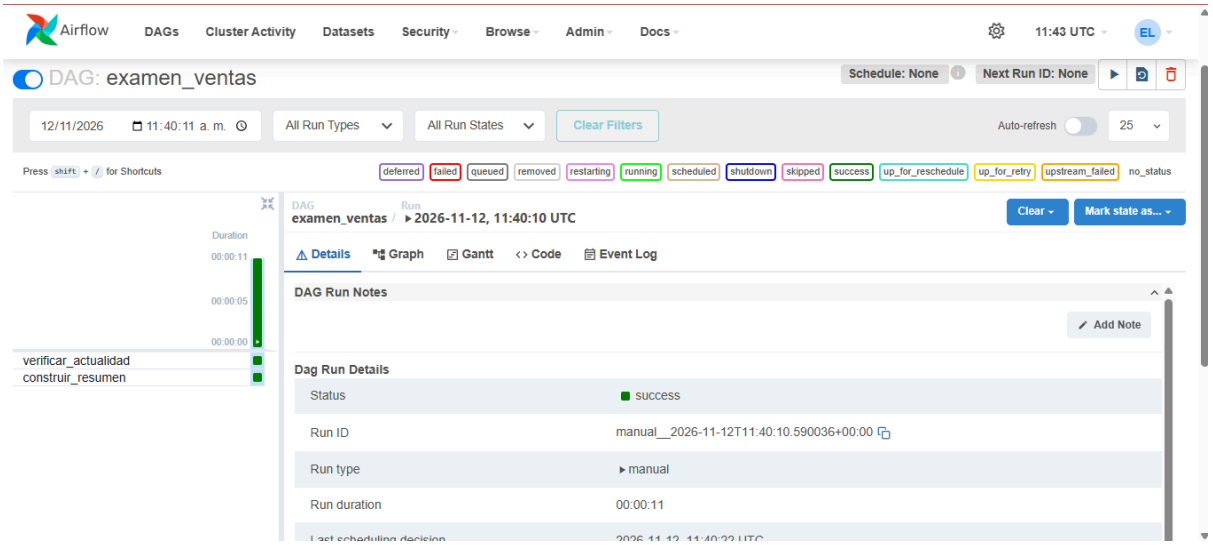
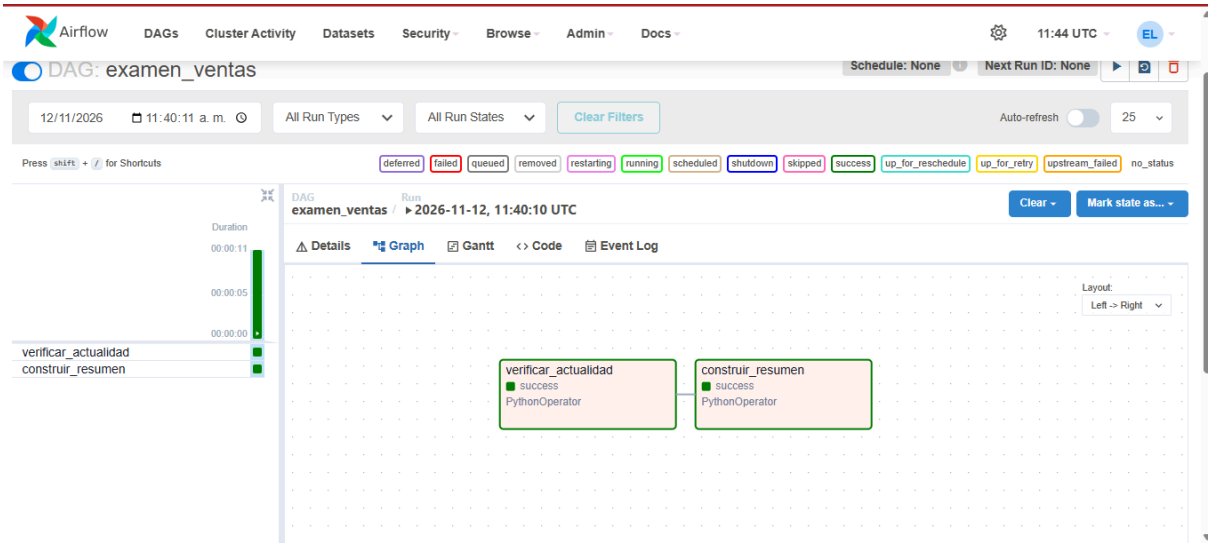
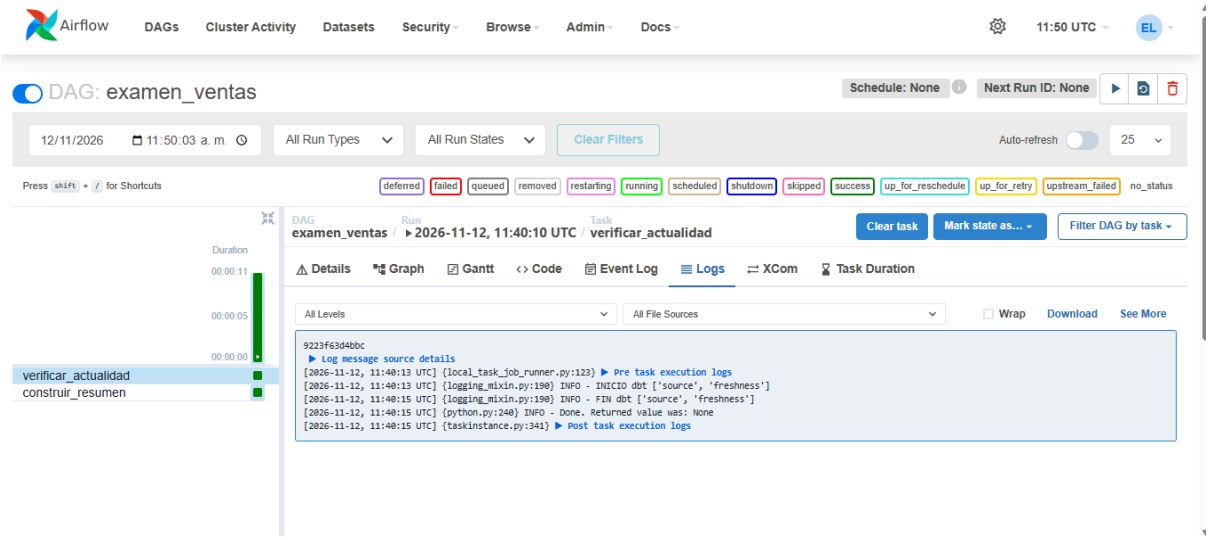
Nombre: Juan José Jaramillo Mora

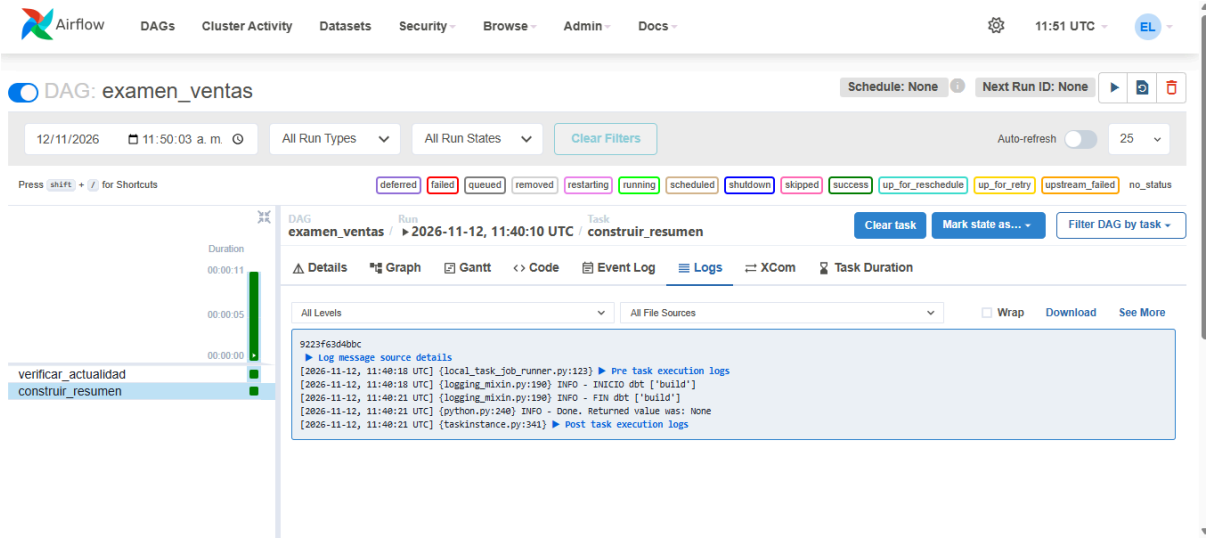
Final Ingeniería de Datos

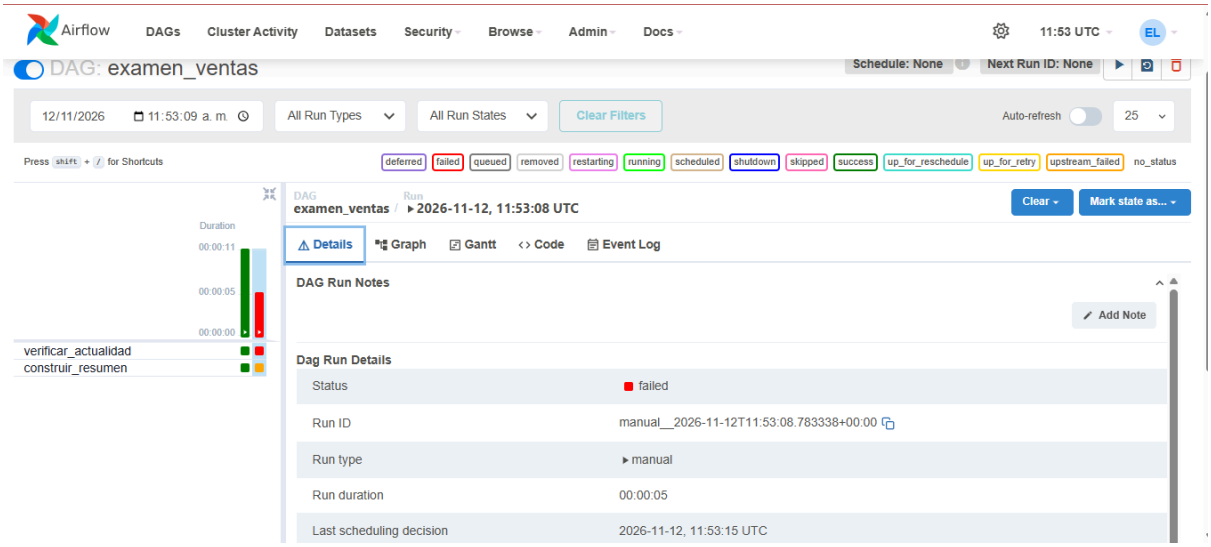
Punto 2 - Ventas diarias con control de actualidad

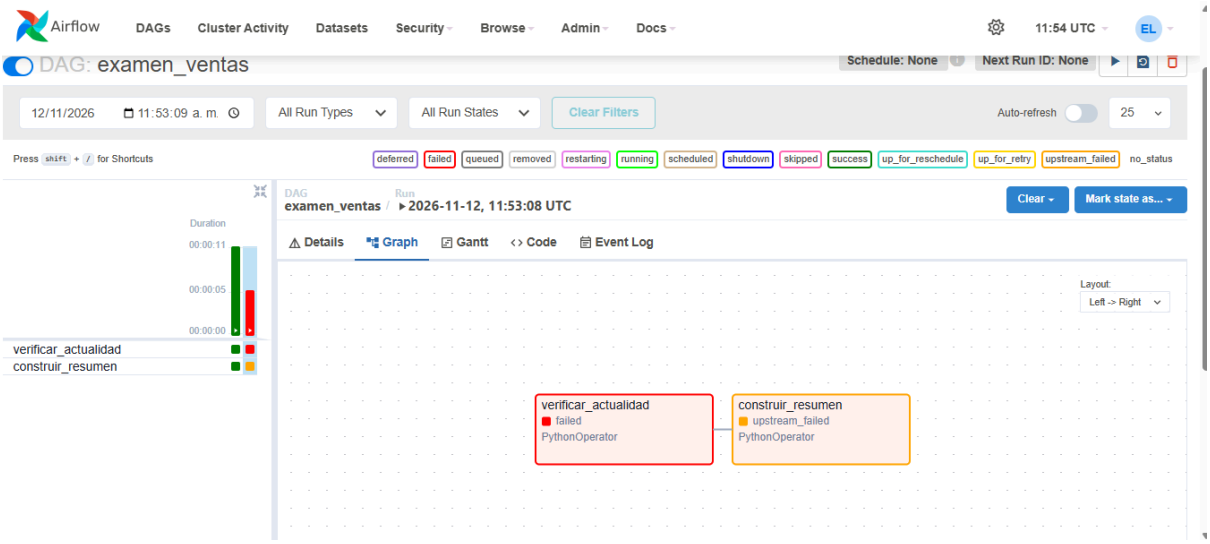


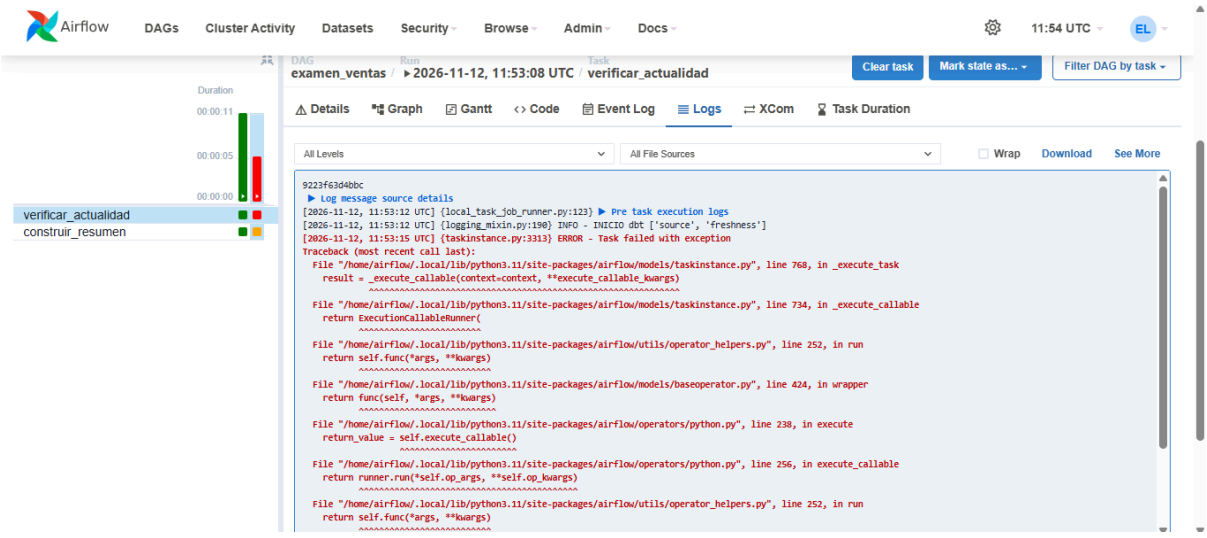


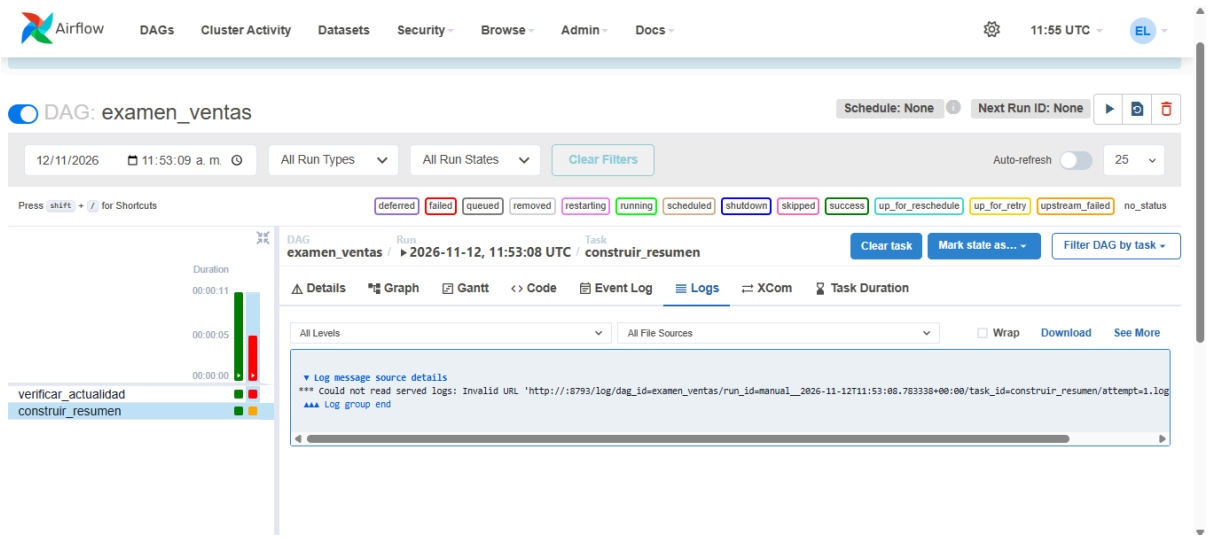

Airflow
DAGs
Cluster Activity
Datasets
Security
Browse
Admin
Docs
11:50 UTC
EL
DAG: examen_ventas
Schedule: None
Next Run ID: None
12/11/2026
11:50:03 a. m.
All Run Types
All Run States
Clear Filters
Auto-refresh
25
Press shift + / for Shortcuts
deferred
failed
queued
removed
restarting
running
scheduled
shutdown
skipped
success
up_for_reschedule
up_for_retry
upstream_failed
no_status
DAG
examen_ventas
Run
2026-11-12, 11:40:10 UTC
Task
verificar_actualidad
Clear task
Mark state as...
Filter DAG by task
Duration
00:00:11
00:00:05
00:00:00
verificar_actualidad
construir_resumen
Details
Graph
Gantt
Code
Event Log
Logs
XCom
Task Duration
All Levels
All File Sources
Wrap
Download
See More
9223f63d4bbc
Log message source details
[2026-11-12, 11:40:13 UTC] {local_task_job_runner.py:123} Pre task execution logs
[2026-11-12, 11:40:13 UTC] {logging_mixin.py:190} INFO - INICIO dbt ['source', 'freshness']
[2026-11-12, 11:40:15 UTC] {logging_mixin.py:190} INFO - FIN dbt ['source', 'freshness']
[2026-11-12, 11:40:15 UTC] {python.py:240} INFO - Done. Returned value was: None
[2026-11-12, 11:40:15 UTC] {taskinstance.py:341} Post task execution logs


Airflow
DAGs
Cluster Activity
Datasets
Security
Browse
Admin
Docs
11:51 UTC
EL
DAG: examen_ventas
Schedule: None
Next Run ID: None
12/11/2026
11:50:03 a. m.
All Run Types
All Run States
Clear Filters
Auto-refresh
25
Press shift + / for Shortcuts
deferred
failed
queued
removed
restarting
running
scheduled
shutdown
skipped
success
up_for_reschedule
up_for_retry
upstream_failed
no_status
DAG
examen_ventas
Run
2026-11-12, 11:40:10 UTC
Task
construir_resumen
Clear task
Mark state as...
Filter DAG by task
Duration
00:00:11
00:00:05
00:00:00
verificar_actualidad
construir_resumen
Details
Graph
Gantt
Code
Event Log
Logs
XCom
Task Duration
All Levels
All File Sources
Wrap
Download
See More
9223f63d4bbc
Log message source details
[2026-11-12, 11:40:18 UTC] {local_task_job_runner.py:123} Pre task execution logs
[2026-11-12, 11:40:18 UTC] {logging_mixin.py:190} INFO - INICIO dbt ['build']
[2026-11-12, 11:40:21 UTC] {logging_mixin.py:190} INFO - FIN dbt ['build']
[2026-11-12, 11:40:21 UTC] {python.py:240} INFO - Done. Returned value was: None
[2026-11-12, 11:40:21 UTC] {taskinstance.py:341} Post task execution logs


Airflow
DAGs
Cluster Activity
Datasets
Security
Browse
Admin
Docs
11:53 UTC
EL
DAG: examen_ventas
Schedule: None
Next Run ID: None
12/11/2026
11:53:09 a. m.
All Run Types
All Run States
Clear Filters
Auto-refresh
25
Press shift + / for Shortcuts
deferred
failed
queued
removed
restarting
running
scheduled
shutdown
skipped
success
up_for_reschedule
up_for_retry
upstream_failed
no_status
DAG
examen_ventas
Run
2026-11-12, 11:53:08 UTC
Clear
Mark state as...
Duration
00:00:11
00:00:05
00:00:00
verificar_actualidad
construir_resumen
Details
Graph
Gantt
Code
Event Log
DAG Run Notes
Add Note
Dag Run Details
Status
failed
Run ID
manual__2026-11-12T11:53:08.783338+00:00
Run type
manual
Run duration
00:00:05
Last scheduling decision
2026-11-12, 11:53:15 UTC


Airflow
DAGs
Cluster Activity
Datasets
Security
Browse
Admin
Docs
11:54 UTC
EL
DAG: examen_ventas
Schedule: None
Next Run ID: None
12/11/2026
11:53:09 a. m.
All Run Types
All Run States
Clear Filters
Auto-refresh
25
Press shift + / for Shortcuts
deferred
failed
queued
removed
restarting
running
scheduled
shutdown
skipped
success
up_for_reschedule
up_for_retry
upstream_failed
no_status
Duration
00:00:11
00:00:05
00:00:00
verificar_actualidad
construir_resumen
DAG
examen_ventas
Run
2026-11-12, 11:53:08 UTC
Clear
Mark state as...
Details
Graph
Gantt
Code
Event Log
Layout:
Left -> Right
verificar_actualidad
failed
PythonOperator
construir_resumen
upstream_failed
PythonOperator


Airflow
DAGs
Cluster Activity
Datasets
Security
Browse
Admin
Docs
11:54 UTC
EL
DAG
examen_ventas
Run
2026-11-12, 11:53:08 UTC
Task
verificar_actualidad
Clear task
Mark state as...
Filter DAG by task
Details
Graph
Gantt
Code
Event Log
Logs
XCom
Task Duration
All Levels
All File Sources
Wrap
Download
See More
9223f63d4bbc
Log message source details
[2026-11-12, 11:53:12 UTC] {local_task_job_runner.py:123} Pre task execution logs
[2026-11-12, 11:53:12 UTC] {logging_mixin.py:190} INFO - INICIO dbt ['source', 'freshness']
[2026-11-12, 11:53:15 UTC] {taskinstance.py:3313} ERROR - Task failed with exception
Traceback (most recent call last):
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/models/taskinstance.py", line 768, in _execute_task
result = _execute_callable(context=context, **execute_callable_kwargs)
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/models/taskinstance.py", line 734, in _execute_callable
return ExecutionCallableRunner(
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/utils/operator_helpers.py", line 252, in run
return self.func(*args, **kwargs)
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/models/baseoperator.py", line 424, in wrapper
return func(self, *args, **kwargs)
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/operators/python.py", line 238, in execute
return_value = self.execute_callable()
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/operators/python.py", line 256, in execute_callable
return runner.run(*self.op_args, **self.op_kwargs)
File "/home/airflow/.local/lib/python3.11/site-packages/airflow/utils/operator_helpers.py", line 252, in run
return self.func(*args, **kwargs)


Airflow
DAGs
Cluster Activity
Datasets
Security
Browse
Admin
Docs
11:55 UTC
EL
DAG: examen_ventas
Schedule: None
Next Run ID: None
12/11/2026
11:53:09 a. m.
All Run Types
All Run States
Clear Filters
Auto-refresh
25
Press shift + / for Shortcuts
deferred
failed
queued
removed
restarting
running
scheduled
shutdown
skipped
success
up_for_reschedule
up_for_retry
upstream_failed
no_status
Duration
00:00:11
00:00:05
00:00:00
verificar_actualidad
construir_resumen
DAG
examen_ventas
Run
2026-11-12, 11:53:08 UTC
Task
construir_resumen
Clear task
Mark state as...
Filter DAG by task
Details
Graph
Gantt
Code
Event Log
Logs
XCom
Task Duration
All Levels
All File Sources
Wrap
Download
See More
Log message source details
*** Could not read served logs: Invalid URL 'http://:8793/log/dag_id=examen_ventas/run_id=manual__2026-11-12T11:53:08.783338+00:00/task_id=construir_resumen/attempt=1.log
Log group end

Preguntas Conceptuales:

1. **¿Por qué usar "_loaded_at" y no "fecha_venta" para este control?**

Porque lo que queremos vigilar es si la carga está al día, no cuándo ocurrieron las ventas. _loaded_at marca el momento en que cada fila llegó a raw, y su máximo dice cuánto tiempo pasó desde la última carga. fecha_venta es una fecha de negocio: una venta vieja puede cargarse hoy. En este examen todas las ventas son de enero de 2026. Si midiéramos con fecha_venta, el control fallaría siempre, incluso con una carga de hace 2 horas. Además, si se cargara hoy un lote de ventas antiguas, fecha_venta mostraría datos viejos aunque la carga fuera reciente. Lo comprobamos: en los tres escenarios los datos de negocio son idénticos y solo cambia _loaded_at, y aun así freshness dio PASS, WARN y ERROR STALE según esa marca.

2. **¿Por qué las pruebas de integridad no garantizan actualidad?**

Porque revisan la forma y el contenido de los datos, no su antigüedad. **"unique", "not_null"** y la prueba de valores confirman que no hay duplicados, nulos ni cantidades inválidas, y eso se cumple igual con datos de hace 2 horas que de hace 30. En el escenario desactualizado, esas mismas filas habrían pasado las 19 pruebas del build sin problema. Además, **"dbt build"** no ejecuta freshness: hay que llamar dbt source freshness explícitamente. Por eso lo pusimos como tarea previa en Airflow. Con 30 horas, verificar_actualidad falla, construir_resumen queda en upstream_failed y se conserva el resumen anterior, en vez de reconstruirlo con datos viejos que parecían correctos.

Punto 1 - Entregas (Arquitectura en AWS)

1. **¿Por qué se pudo consultar el tercer día sin registrar una partición nueva?**

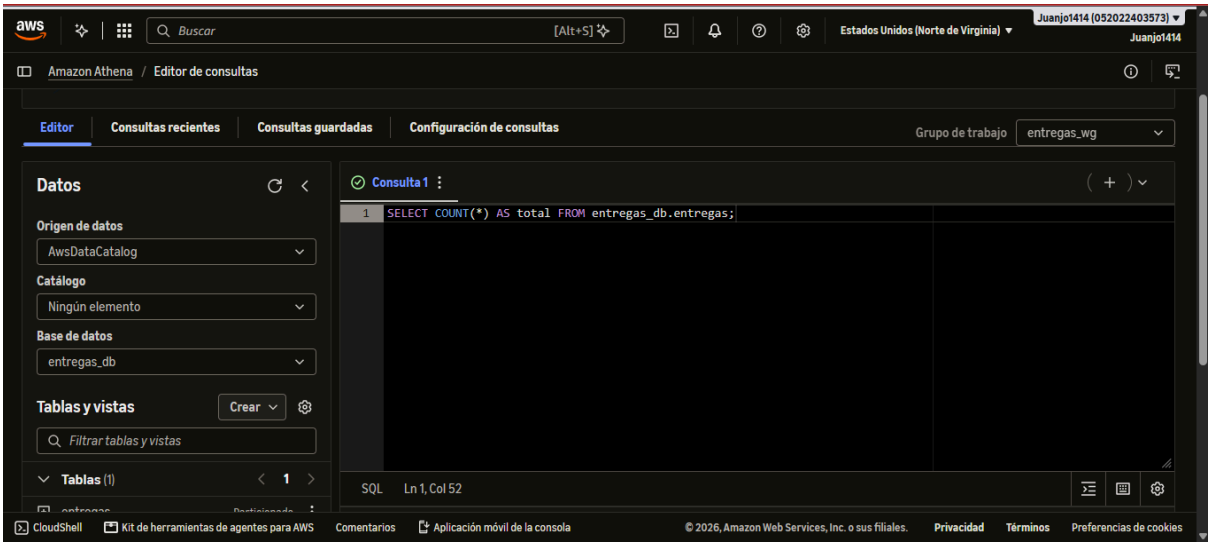
Porque la tabla no depende de una lista de particiones guardada en Glue. Con partition projection, Athena calcula las particiones en el momento de la consulta a partir de las reglas que dejamos en las propiedades de la tabla: `projection.fecha.type = date`, formato `yyyy-MM-dd`, rango `2026-10-01,2026-10-03` e intervalo de 1 día. Con esas reglas, Athena genera las fechas 2026-10-01, 2026-10-02 y 2026-10-03 y, con `storage.location.template`, arma el prefijo de cada una: `s3://<bucket>/entregas/fecha=<fecha>/`.

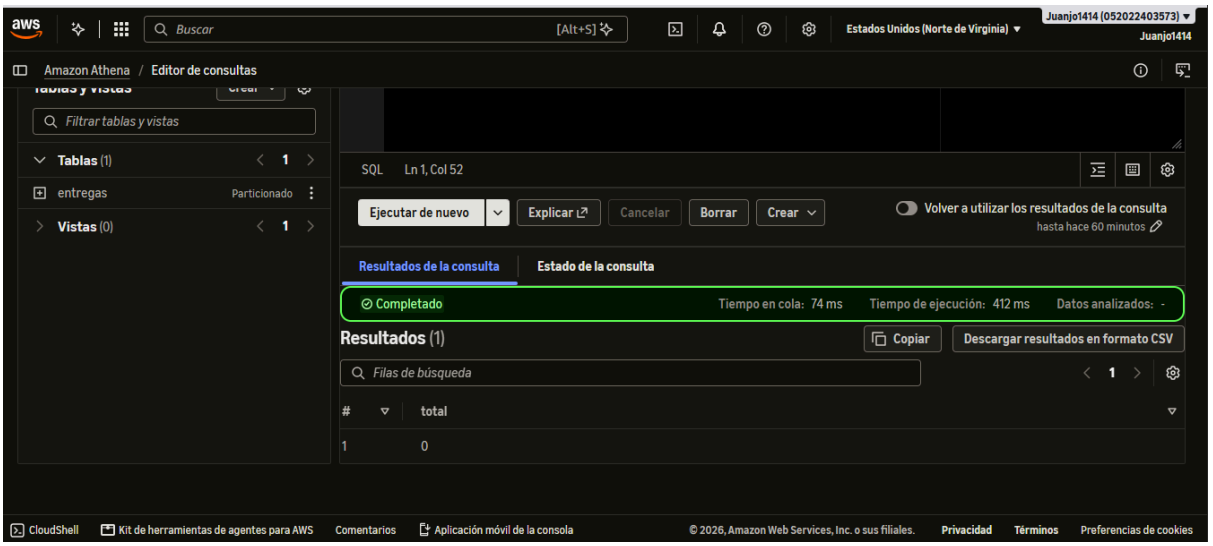
El 2026-10-03 estaba proyectado desde el despliegue inicial. En la primera etapa su prefijo no tenía objetos, así que Athena no encontró filas para esa fecha: los resultados iniciales solo muestran el 1 y el 2 de octubre, con 12 registros. Cuando subimos `entregas/fecha=2026-10-03/entregas.csv`, la misma ruta que Athena ya calculaba pasó a tener un archivo. La siguiente consulta lo leyó directamente: `verificacion_tercer_dia.csv` muestra los seis registros (ENV-013 a ENV-018), el conteo por estado da 3 `destinatario_ausente`, 1 `direccion_incorrecta` y 2 `entregado`, y la tabla pasó a 18 registros. Los resultados finales de intentos y porcentaje coinciden con las referencias. No corrimos crawlers, `MSCK REPAIR TABLE` ni `ALTER TABLE ADD PARTITION`, ni cambiamos la tabla.

2. **Si se subiera un archivo para el 4 de octubre manteniendo la configuración actual, ¿qué resultado se esperaría y qué se debería modificar para incluirlo?**

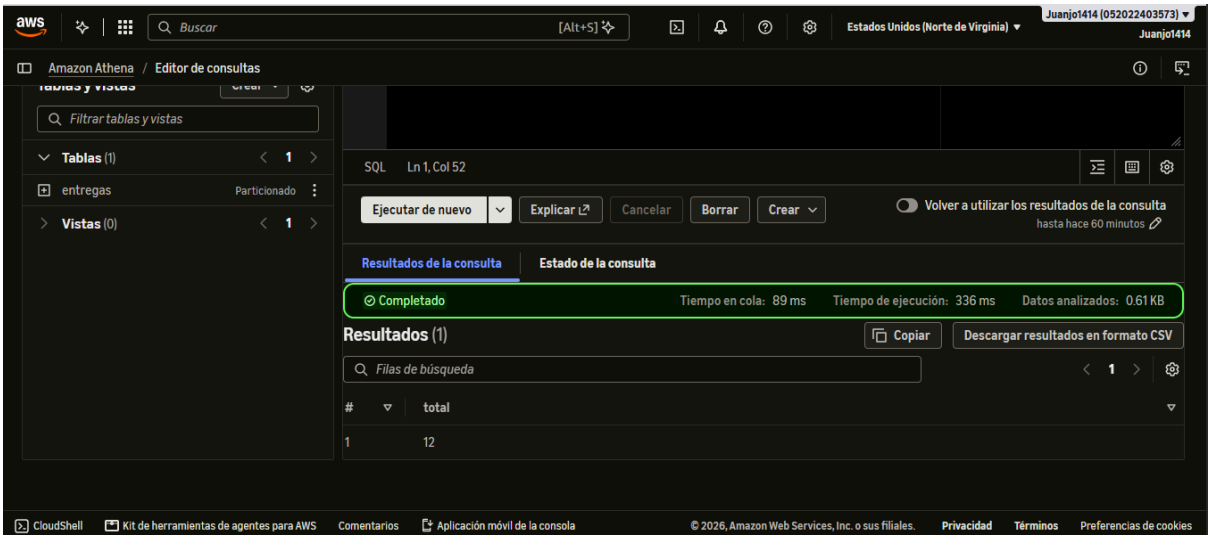
El archivo quedaría guardado en S3, pero Athena no lo leería. El rango proyectado termina en 2026-10-03, así que Athena nunca genera la fecha 2026-10-04 ni construye su ruta. Las consultas seguirían devolviendo 18 registros y tres fechas, y un filtro `WHERE fecha = '2026-10-04'` devolvería cero filas sin error. La proyección no lista S3 buscando carpetas nuevas: solo considera las fechas que caen dentro de su rango.

Para incluirlo habría que ampliar `projection.fecha.range`, por ejemplo a `2026-10-01,2026-10-31`, o usar un extremo relativo como `2026-10-01,NOW`. Como toda la tabla está en Terraform, el cambio se hace en la variable `rango_fechas` y se aplica con `terraform apply`, no desde la consola. Después de ese cambio no hace falta registrar la partición: basta con que el archivo esté en `entregas/fecha=2026-10-04/entregas.csv`. Con un rango amplio, las fechas sin archivo simplemente no aportan filas.





Luego de la carga de archivos en S3:



Luego de otra carga en S3:

